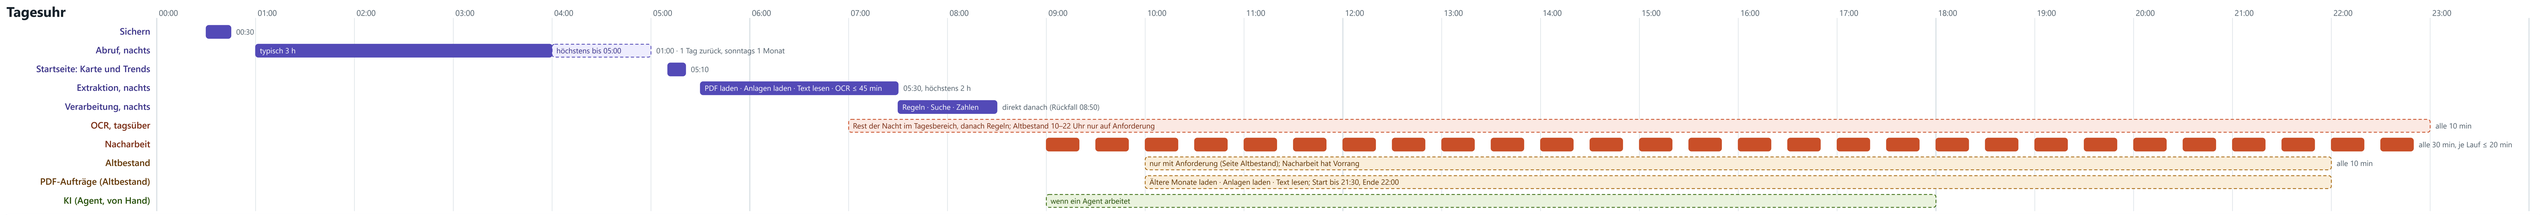
Plenara · Betriebsplan der Server-Pipeline

Prozesstapete: Tagespipeline, Fehlerspeicher, Nacharbeit, Altbestand und KI mit allen Verzweigungen · Stand 15.10.2026 · Branch betriebsplan, noch nicht ausgerollt · Namen aus shared/pipeline-terms.mjs

Tagespipeline · Nacharbeit, Fehlerspeicher · Altbestand · KI · Speicher
Ablauf · Fehler → Fehlerspeicher · Wiederholung, Folgekette · Auslöser · Entscheidung

Tagesuhr



Tagespipeline

jede Nacht, feste Reihenfolge; was scheitert, kommt in den Fehlerspeicher, die Pipeline wartet nicht

Sichern und Stufe 1: Abruf

00:30 Sichern — Datenbank, Index und Texte der PDF-Ablage → backups/ (2 Stände; mit BACKUP_REMOTE außer Haus)

Sonntag?
- ja → Fenster 1 Monat
- nein → Fenster 1 Tag

01:00 Abruf, nachts — Auftrag für alle angebundenen Quellen; dazu angesetzte künftige Sitzungen

Gebiet oder sein Server wartet im Fehlerspeicher?
- ja → Zurückgestellt — bis zum Termin; die Nacharbeit holt es
- nein → **Abruf je Gebiet** — runSync; 24 Bahnen, je Server höchstens 2

Ergebnis je Gebiet?
- ok → gespeichert — topics, Suche, Werte je Gebiet; Eintrag gelöscht, Server liefert
- Zeit → Zeitgrenze erreicht — Teil n: nächste Nacht hinter dem Cursor
- Quelle bremst · Fehler

05:10 Startseite — nach allen Gebieten: Karte und Trends vorrechnen

weiter mit der Extraktion

Stufe 2: Extraktion (05:30, „Extraktion, nachts", höchstens 2 h)

Auswahl — seit dem letzten Lauf geschrieben + alle mit Sitzung im Tagesbereich (2 Indexabfragen)

PDF laden — Hauptdokumente, ≤ 29 min

Anlagen laden — übrige PDFs, ≤ 19 min; in der Grenze unter allen Hauptdokumenten

Text lesen — Textebene

Seiten ohne Text?
- nein → Dokumentart, Stand zählen — dann Verarbeitung anstoßen
- ja → **OCR** — Hauptdokumente zuerst, ≤ 45 min → Dokumentart, Stand zählen

stößt an

Server?
- wartet → wartet: auslassen — Dokument bleibt offen
- fällig → fällig: Stichprobe — 3 Dokumente; eine gelingt → liefert, der Rest folgt
- liefert

Antwort?
- 404 · kein PDF → fehlt dauerhaft — 404, 410, kein PDF, über 30 MB
- PDF → Platz in der 80-GB-Grenze?
  - ja → behalten — Text gleich gelesen
  - voll → Tausch — besser als die schlechteste Datei: die fliegt raus (Text bleibt), sonst die neue
  - über 10 MB — nur der Text bleibt
- 429 · 403 · Timeout · 5xx

Seite > 90 s oder Datei > 5 min?
- nein → 45 Minuten um?
- nein: nächste Datei
- zu langsam

45 Minuten um?
- ja: Rest → „OCR, tagsüber"

Stufe 3: Verarbeitung („Verarbeitung, nachts")

Titel einordnen — nur fehlende oder veraltete Einordnungen

Regeln anwenden — Art des Punkts, Thema, Regel-Zusammenfassung, Fakten

Suche aktualisieren — Wortliste nachführen

Zahlen rechnen — plenara.X

KI-Stand, Wege zählen — Zähler für Pipeline-Debug und Altbestand

fertig — die KI arbeitet von Hand (Bahn KI); neuer Text macht KI-Fassungen „veraltet"

Eingaben geändert? (Schlüssel mit Textstand)
- nein → **übersprungen** — unverändert
- ja → Hauptdokument ist Unterlage der ganzen Sitzung?
  - nein → Regel stürzt ab?
    - nein → **gespeichert** — Payload, report_rules, topic_facts: per Trigger die Suchkarte
    - ja → Fehler im eigenen Code
  - ja → **keine Zusammenfassung** — Art, Thema bleiben

Fehlerspeicher

work_failures und source_hosts (Migration 0040); entscheidet, wann erneut

jeder Fehlschlag: recordFailure; jeder Erfolg löscht den Eintrag (clearFailure)

Eintrag schreiben — Schritt, Gegenstand, Grund, Versuche, nächster Termin, Sitzungstag, Herkunft; ein neuer Fehlschlag ersetzt den alten

Grund?
- Quelle bremst (429, 503, Abweisung) — Server wartet 1 h bis 7 Tage, dann Stichprobe
- Zugriff verweigert (401, 403, 451) — Server wartet 7 bzw. 30 Tage, dann „prüfen"
- vorübergehend (Timeout, keine Antwort, 5xx) — neuer Versuch nach 1 h, 6 h, 1 Tag, 3 Tagen
- fehlt dauerhaft (404, 410, kein PDF, > 30 MB, geändert) — kein neuer Versuch (404, kein PDF, zu groß)
- zu langsam (OCR über der Zeitgrenze) — ein zweiter Versuch mit 15 Minuten je Datei, danach nur die Textebene
- Sperre im Haus (409, Datenbank gesperrt) — neuer Versuch nach 10 Minuten
- Fehler im eigenen Code (Ausnahme im eigenen Code) — neuer Versuch nach dem nächsten Deploy

Altfehler übertragen — beim ersten Lauf: alte Abruf- und OCR-Fehler der Ablage und die alte Serversperre, alle als Altbestand

Endgültig ist nur „fehlt dauerhaft" und eine OCR, die auch beim zweiten Versuch zu langsam ist; alles andere läuft regelmäßig weiter.

Serverstufe je Server (source_hosts)

liefert — ok
- 429, 503 sofort → bremst — 1 h → 4 h → 12 h → 1 Tag → 3 Tage → 7 Tage
- 3 Fehler in Folge → gesperrt — 7 Tage → 30 Tage → prüfen — Stichprobe alle 30 Tage
- 3 × verweigert in Folge (401, 403, 451) → gesperrt

In der Wartezeit lassen alle Abrufer den Server aus (Abruf, PDF laden, OCR-Nachladen); seine Einträge zählen keine Versuche.

Termin erreicht?
- ja → **Stichprobe** — 3 Einträge des Servers
- eine gelingt?
  - ja → liefert wieder — Rest folgt
  - nein → Stufe + 1 — neue, längere Wartezeit
- nein: warten

„Freigeben" (Pipeline-Debug, Altbestand) zieht die Prüfung vor.

Tagesbereich oder Altbestand?

Sitzung höchstens 7 Tage zurück (oder künftig), frühestens 12.10.2026, und Fehler nicht vor dem 12.10.?
- nein → **Altbestand** — nur auf Knopfdruck: Seite Altbestand (10–22 Uhr)
- ja → **Tagesbereich** — automatisch: Nacharbeit (09–23 Uhr), OCR tagsüber

Wandert von selbst — Nach 7 Tagen gehört ein Eintrag zum Altbestand; die Nacharbeit lässt ihn dann liegen. Herkunft „Altbestand" (übertragene Altfehler, Läufe des Altbestands) gehört nie zum Tagesbereich. Ohne Sitzungstag zählt der erste Fehlschlag.

Nichts wird dauerhaft vergessen

- vorübergehend: nach der Leiter wöchentlich weiter
- Zugriff verweigert: monatlich weiter; Server in „prüfen" alle 30 Tage Stichprobe
- Eintrag ohne Termin (eigener Code) hält den Nachtabruf nicht auf
- sonntags Abruf 1 Monat zurück: spät veröffentlichte Niederschriften und Beschlüsse
- Extraktion nimmt auch alle Berichte mit Sitzung im Tagesbereich (OParl: updated_at ist das Änderungsdatum der Quelle)
- nicht drangekommen: eine Stunde weiter, nicht jede halbe Stunde
- bei gleichem Sitzungstag kommen die mit den wenigsten Versuchen zuerst
- die Seiten zeigen je Grund: jetzt fällig · wartet · kein Versuch mehr

fällige Einträge des Tagesbereichs → Nacharbeit

Nacharbeit

tagsüber automatisch, nur Tagesbereich; Stufe für Stufe, mit Folgekette

Zeitplaner — alle 30 min, 09:00 bis 23:00

Bahn „Laden" frei?
- ja → **Auswahl (dueEntries)** — fällig im Tagesbereich, Server nicht wartend. Reihenfolge: Abruf → Extraktion → Verarbeitung; neueste Sitzung; wenigste Versuche; am längsten nicht versucht. Je Server ≤ 20 (fällige 3), je Lauf ≤ 500 Einträge, ≤ 20 min
- nein → lässt aus — nächster Lauf

- Abruf — import-worker --direct; Fenster seit dem ersten Fehlschlag, mindestens 1 Woche
- PDF laden — fetch.mjs --urls
- Text lesen, OCR — text.mjs --shas; OCR mit 15 min je Datei (zweiter Versuch)
- Regeln anwenden — read-reports.mjs --ids

Ausgang je Eintrag?
- gelungen → **gelungen: Folgekette** — nach Abruf: PDF laden, Anlagen laden, Text lesen, OCR, Regeln anwenden für die geschriebenen Berichte · nach PDF laden: Text lesen, OCR, Regeln · nach Text lesen/OCR: Regeln
  - → **bereit für die KI** — Zähler im Protokoll (nacharbeit-last)
- nicht drangekommen — Server wartet, Zeitgrenze → eine Stunde weiter

gescheitert: neuer Termin nach Grund · kein Versuch mehr

Altbestand → Job „Altbestand" (nur angefordert)

„OCR, tagsüber" (eigene Einheit; Anhalten trifft nur die OCR)

Zeitplaner — alle 10 min, 07:00 bis 23:00

Reihe des Tagesbereichs — Rest der Nacht; Hauptdokumente vor Anlagen, abgelegte vor gelöschten (kurz nachgeladen), neueste Sitzung; wartende Einträge ausgelassen

OCR in Paketen — 25 Dateien je Prozess, 2 Worker; Seite ≤ 90 s, Datei ≤ 5 min; Wächter beendet Pakete ohne Lebenszeichen nach 3 min

zu langsam, Nachladen gescheitert → Fehlerspeicher

Altbestand angefordert und 10–22 Uhr?
- ja → **OCR des Altbestands** — 15 min je Datei, auch zu langsame vom letzten Mal
- nein → Dateien gelesen?
  - nein → endet sofort — kein Protokoll
  - ja → „Verarbeitung, nachts" läuft?
    - ja → Text kommt dort an — nächster Lauf liest den Bericht
    - nein → **Dokumentart → Regeln anwenden → Suche aktualisieren** — für die Berichte, deren Text die OCR gerade ergänzt hat (Folgekette) → **KI: „veraltet"** — neuer Text ändert den Eingabehash

Wo die Nacharbeit herkommt und wohin sie führt

Sie liest nur den Tagesbereich des Fehlerspeichers. Gelingt ein Schritt, verschwindet der Eintrag und die nächste Stufe läuft für dieselben Berichte (Folgekette): ein erneut gelungener Abruf führt so bis zu Regeln und KI-Bereitschaft. Scheitert er, gibt der Grund den nächsten Termin. Hält ein Auftrag des Altbestands oder die Nacht die Bahn „Laden", lässt sie aus.

Altbestand

nur auf Knopfdruck, 10 bis 22 Uhr; dieselben Schritte wie nachts

Seite Altbestand — /admin?seite=altbestand, Debug-Bereich; liegt nur Wünsche ab (altbestand-requests)

Reiter PDF-Import — „Alte Fehler erneut versuchen", „OCR des Altbestands" fordern dasselbe an

- **Rückwirkend abrufen** — Gebiete (alle oder Liste), 1, 3, 12 oder 24 Monate
- **Alte Fehler erneut versuchen** — alle, je Stufe oder je Grund; macht auch „kein Versuch mehr" wieder fällig
- **Ältere Monate laden · Anlagen laden · Text lesen** — Aufträge der PDF-Ablage
- **OCR des Altbestands** — anfordern, anhalten
- **Verarbeitung jetzt · alle neu** — Berichte mit neuen Eingaben, oder alle

Job „Altbestand" — alle 10 min, 10:00 bis 22:00, nur mit Anforderung; je Lauf ≤ 2 h, endet 22:00

Nacharbeit hat Fälliges und lief > 25 min nicht?
- ja → lässt aus — Vorrang des Tagesbereichs
- nein →
  - **1. Alte Fehler** — Nacharbeit mit Bereich Altbestand, Stufe für Stufe mit Folgekette, bis nichts mehr fällig ist
  - **2. Rückwirkender Abruf** — je 8 Gebiete über import-worker --direct; jedes gelungene gleich mit Extraktion und Regeln; erledigt und gescheitert gemerkt; fortsetzbar über Tage, anhaltbar

→ **Folgekette wie in der Nacharbeit** — Abruf → PDF laden, Anlagen laden, Text lesen, OCR → Regeln anwenden; Fehler mit Herkunft Altbestand zurück in den Fehlerspeicher; gelungen: Eintrag weg, Bericht für die KI bereit

Job „PDF-Aufträge" — startet bis 21:30, endet 22:00; einer zur Zeit; Fehler als Altbestand

Job „OCR, tagsüber": nach dem Tagesbereich — 10 bis 22 Uhr, bis angehalten

Job „Verarbeitung, nachts" sofort — Titel einordnen, Regeln anwenden (geänderte Eingaben oder alle), Suche, Zahlen

Fehler mit Herkunft Altbestand → Fehlerspeicher

Warum getrennt

Die Nacht gehört der Tagespipeline, tagsüber hat die Nacharbeit Vorrang. Der Altbestand ist groß (Stand 14.10.: 84.489 alte Abruffehler, rund 40.000 Anlagen mit 270.000 Seiten ohne Text, 32.088 Dokumente auf Servern, die 401/403 liefern) und darf Wochen brauchen; er läuft nur, wenn jemand ihn anfordert, Paket für Paket und fortsetzbar. Was er schafft, landet in denselben Speichern und wird wie nachts weiterverarbeitet.

Was endgültig bleibt (mit Zahl auf den Seiten)

Adressen mit 404 oder 410, Antworten ohne PDF, PDFs über 30 MB, Dateien, die sich beim Nachladen geändert haben, und OCR-Dateien, die auch mit 15 Minuten zu langsam sind (die Textebene bleibt). „Erneut versuchen" im Altbestand öffnet sie wieder.

KI

von Hand über den Agenten; keine automatische Modell-API

↻ wieder bearbeiten

Liste: bereit, veraltet — ai_list; Zähler auf Pipeline-Debug und Altbestand

claim — Reservierung

read — alle PDFs des Berichts (Hauptdokument und Anlagen), alle Seiten

Quelle reicht?
- ja → **submit** — Kurzfassung, Langfassung, KI-Einordnung gemeinsam; Eingabehash geprüft
- nein → **Quelle reicht nicht** — neuer Versuch erst bei geänderten Quelldaten

neuer Text → „veraltet" — OCR, Nacharbeit oder Altbestand ergänzen Text → Eingabehash ändert sich → der Bericht kommt wieder in die Liste

Ergebnis — topics.payload (Kurz- und Langfassung, KI-Einordnung), article_analyses, ai_usage; Regel-Zusammenfassung und manuelle Einordnungen bleiben erhalten

Speicher

Hauptdatenbank ratsmonitor.sqlite: topics, article_versions, source_coverage, import_runs, search_cards, search_words, report_rules, topic_facts, x_cases, ai_work_items, work_failures, source_hosts, system_state (Aufträge, Laufbuch schedule-log, pdf-daily-last, altbestand-requests, ai-counts, pipeline-trace) · PDF-Ablage RM_PDF_STORE: index.sqlite (pdfs, texts), files/<ab>/<sha>.pdf und .txt (80 GB für PDFs und Texte) · backups/

Admin-Seiten

Jobs & Zeitpläne: alle Jobs mit Zeit oder Fenster · PDF-Import: Ablage, Aufträge, Server nach Serverstufe · Themen & Texte: Verarbeitung je Schritt · Pipeline-Debug (vorübergehend): Tagesuhr, Läufe, Wege der Berichte, Fehlerspeicher des Tagesbereichs · Altbestand: Abruf, Extraktion, Verarbeitung, alte Fehler

Begriffe

Tagesbereich: Sitzungen der letzten 7 Tage, frühestens 12.10.2026 · Folgekette: gelingt eine Stufe, startet die nächste für dieselben Berichte · Stichprobe: 3 Einträge eines fälligen Servers · Stufen: Abruf, Extraktion, Verarbeitung · Quelle: requirements/betriebsplan-konzept.md